

SVM

Chceme všechny body rozdělit podrovinou, která má co největší vzdálenost od všech bodů z datasetu. Tzn. hledáme w, b takové, že

$$\operatorname{argmax}_{w,b} \frac{1}{\|w\|} \min_i (t_i (\phi(x_i)^T w + b))$$

Vzdálenost od přímky můžeme přeškálovat tak, aby nejbližší bod byl vzdálený 1, celý vzorec můžeme přepsat na

$$\operatorname{argmin}_{w,b} \frac{1}{2} \|w\|^2 \text{ pokud } t_i y(x_i) \geq 1$$

KKT

Lagrangian takové funkce pak vypadá

$$L = \sum_i a_i - \sum_i \sum_j a_i a_j t_i t_j \varphi(x_i) \varphi(x_j)$$

ale derivace nám stanovuje nějaké podmínky

$$a_i \geq 0, t_i y(x_i) - 1 \geq 0, a_i (t_i y(x_i) - 1) = 0$$

To znamená, že bod je buď na rozhodovací hranici, nebo $a_i = 0$. Bodům na rozhodovací hranici můžeme říkat podpůrné vektory, $y(x) = \sum_i a_i t_i K(x, x_i) + b$

Lineární neseparabilní

Kdybychom požadovali po modelu, aby všechna data klasifikoval správně, model by mohl začít overfitovat a to nechceme. Místo toho vytvoříme soft margin, tzn. nebude nám vadit, když nějaká data budou klasifikovaná špatně, za to budeme mít penaltu ξ_i . Chceme tedy najít

$$\operatorname{argmin}_{w,c} C \sum_i \xi_i + \frac{1}{2} \|w\|^2 \text{ pokud } t_i y(x_i) \geq 1 - \xi_i, \xi_i \geq 0$$

Optimalizujeme stejnou funkci jako předtím, ale navíc máme podmínku $C \geq a_i$